

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

KHOA HỆ THỐNG THÔNG TIN

Tài liệu bài giảng:

PHÂN TÍCH DỮ LIỆU KINH DOANH – IS403

Chương 1:

Tổng quan

ThS. Dương Phi Long – Email: longdp@uit.edu.vn

NỘI DUNG BÀI HỌC

01



Tổng quan về PTDLKD

02



Dữ liệu và các phép biến đổi dữ liệu

03



Phân tích thống kê cơ bản và cách đọc dữ liệu

04




Đo lường dữ liệu

05



Trực quan hóa dữ liệu






1

Tổng quan về PTDLKD

1. Phân tích dữ liệu
2. Phân tích dữ liệu kinh doanh



"The future of data analysis", 1962

This is my favorite part
about analytics:

Taking boring flat data and bringing
it to life through visualization.

- John Tukey



"Exploratory Data Analysis", 1977

Phương pháp phân tích thông qua các công cụ trực quan dữ liệu
(các biểu đồ), các khái niệm như trung bình, trung vị, phân vị

"Statistics has contributed much
to data analysis. In the future it
can, and in my view should,
contribute much more."

-John W. Tukey

Từ đó, phát triển và hình thành các tri thức về PTDL

1.1. Phân tích dữ liệu

Data Analysis VS Data Analytics

Data Analysis vs. Data Analytics:
What's the Difference?

1.1. Phân tích dữ liệu

- Data analysis vs Data analytics

- Data analysis is the **process of inspecting, cleansing, transforming, and modeling data** with the goal of discovering useful information, informing conclusions, and supporting decision-making.
- Data analytics is **a broad field** that involves the collection, analysis, and interpretation of data to help an organization make better decisions and achieve its goals. Data analytics converts raw data into actionable insights. It includes a range of **tools, technologies, and processes** used to find trends and solve problems by using data. Data analytics can shape business processes, improve decision-making, and foster business growth.

Xia, B. S., & Gong, P. (2015). Review of business intelligence through data analysis. *Benchmarking*, 21(2), 300-311. doi:10.1108/BIJ-08-2012-0050

1.1. Phân tích dữ liệu

- Data analysis

- Là quá trình tìm kiếm, xử lý và kiểm tra dữ liệu để rút ra thông tin có giá trị, tìm kiếm mối quan hệ hoặc điểm bất thường trong dữ liệu.
- Thường mang tính **thống kê** và **mô tả**, giúp hiểu rõ hơn dữ liệu quá khứ, hiện tại.
- Các loại phổ biến:
 - Phân tích giả thuyết (hypothesis analysis)
 - Phân tích tương quan (correlation analysis),
 - Phân tích hồi quy (regression analysis),
 - ...
- Mục tiêu chính: **hiểu rõ dữ liệu**, tìm ra các mẫu (patterns) hoặc mối quan hệ để hỗ trợ quyết định.



1.1. Phân tích dữ liệu

- Data analytics

- Là một khái niệm rộng hơn, bao gồm việc thu thập, phân tích và giải thích dữ liệu; sử dụng các công cụ, kỹ thuật, công nghệ để phân tích, xử lý dữ liệu nhằm tạo ra những hiểu biết sâu sắc, đưa ra quyết định tốt hơn và đạt được mục tiêu.
- Hữu ích trong nhiều ngành công nghiệp (kinh doanh, chăm sóc sức khỏe, giáo dục và chính phủ, ...)
- Các loại phổ biến:
 - Phân tích mô tả (descriptive analytics)
 - Phân tích chẩn đoán (diagnostic analytics)
 - Phân tích dự báo (predictive analytics)
 - Phân tích đề xuất (prescriptive analytics)
- Tích hợp công nghệ, thuật toán và mô hình (machine learning, các phương pháp phân tích phức tạp khác) để phân tích dữ liệu.



DATA ANALYTICS VS DATA ANALYSIS

Aspect	Data Analysis	Data Analytics
Nature	Descriptive	Predictive & Prescriptive
Focus	Historical & current data	Past, present, and future data
Techniques	Statistical methods, data visualization	Machine learning, predictive modelling
Outcome	Understand patterns and insights	Forecast trends
Goal	Explain what happened	Predict what will happen and recommend actions
Timeframe	Past and present	Past, present, and future


1.1. Phân tích dữ liệu

Descriptive analytics tell us
what happened.

Diagnostic analytics tell us
why something happened.

Predictive analytics tell us
what will likely happen in the future.

Prescriptive analytics tell us
how to act.



1.1. Phân tích dữ liệu

VD 1: Phân tích doanh thu hàng tháng

Descriptive Analytics (Phân tích mô tả):

Tóm tắt các đặc điểm và xu hướng cơ bản trong dữ liệu hiện tại.


- Tìm hiểu về doanh thu hàng tháng trong năm vừa qua.
- Sử dụng các biểu đồ và thống kê cơ bản để tính trung bình doanh thu hàng tháng và sắp xếp theo mùa vụ (tháng 12 thường cao hơn tháng 6).
- Giúp nhận ra xu hướng doanh thu tăng vào cuối năm, không đi sâu vào nguyên nhân.

Sales Trend Analysis

For the rolling 12 months ended 27/04/2018

Rolling Year
All

Month
All




1.1. Phân tích dữ liệu

VD 1: Phân tích doanh thu hàng tháng

Diagnostic Analytics (Phân tích chẩn đoán): Tìm hiểu nguyên nhân của các sự kiện hoặc vấn đề đã xảy ra.

- Tiến hành phân tích nguyên nhân: xem xét dữ liệu về chiến dịch marketing, mức độ cạnh tranh, số lượng khách hàng đến cửa hàng, và các yếu tố khác.
- Giúp xác định nguyên nhân giảm doanh thu: do một chiến dịch quảng cáo kém hiệu quả trong tháng đó, hoặc có thể là vì một sự kiện cạnh tranh mạnh.




1.1. Phân tích dữ liệu

VD 1: Phân tích doanh thu hàng tháng

Predictive Analytics (Phân tích dự báo):

Sử dụng dữ liệu lịch sử để dự đoán xu hướng tương lai, kết quả có thể xảy ra.

- Sử dụng dữ liệu lịch sử bán hàng để dự đoán doanh thu cho các tháng sắp tới, mùa bán hàng cao điểm (tháng 11, 12).
- Có thể sử dụng các mô hình học máy để xác định xu hướng tăng trưởng hoặc suy giảm doanh thu, dựa trên các yếu tố như lịch sử tiêu thụ và các sự kiện đặc biệt.




1.1. Phân tích dữ liệu

VD 1: Phân tích doanh thu hàng tháng

Prescriptive Analytics (Phân tích chỉ dẫn, đề xuất): Đưa ra các khuyến nghị hoặc chiến lược hành động dựa trên dữ liệu và phân tích dự báo.

- Dựa trên dự báo giảm doanh thu vào tháng 6, phân tích đề xuất sẽ gợi ý các chiến lược cụ thể để cải thiện doanh thu: tăng cường marketing, giảm giá sản phẩm, tổ chức sự kiện đặc biệt.
- Có thể sử dụng các thuật toán tối ưu hóa để gợi ý kế hoạch quảng cáo hoặc quyết định về nguồn lực bán hàng.


Prescriptive Analytics Techniques and Methods



1.2. Phân tích dữ liệu kinh doanh

- Business Data Analytics: Quá trình thu thập, xử lý, phân tích và giải quyết dữ liệu kinh doanh để hỗ trợ quyết định.
- Có thể liên kết với nhiều công cụ và kỹ thuật khác nhau như thống kê, máy học, trực quan hóa dữ liệu và các phương pháp khác để phát hiện xu hướng, mô hình hoặc mối quan hệ tiềm năng ẩn trong dữ liệu.
- Mục tiêu là giúp doanh nghiệp hiểu rõ hơn về các yếu tố ảnh hưởng đến hiệu suất, tối ưu hóa hoạt động và tạo ra giá trị từ dữ liệu.





2

Dữ liệu trong PTKD

1. Dữ liệu kinh doanh
2. Các kỹ thuật tiền xử lý dữ liệu

2.1. Dữ liệu kinh doanh

- **Dữ liệu kinh doanh (Business Data):** Các dữ liệu liên quan đến các hoạt động kinh doanh, từ thông tin tài chính, khách hàng, sản phẩm, thị trường đến dữ liệu từ các hệ thống kinh doanh khác như quản lý chuỗi cung ứng, marketing, bán hàng, ...
- Ví dụ:
 - Báo cáo thường niên
 - Kiểm toán kế toán
 - Phân tích lợi nhuận tài chính
 - Xu hướng kinh tế
 - Nghiên cứu tiếp thị, ...

2.1.1. Các loại dữ liệu kinh doanh

- Các loại dữ liệu kinh doanh (dựa trên nguồn gốc):

Unstructured Data

The university has 5600 students. Shaun (ID Number: 160801), 18 years old Communication study. Linh with ID number 160802, majoring in Accounting and is 20 years old. Ahmed from Psychology study program, 19 years old, ID number 160803.

Semi-Structured Data


```
<University>
<ID Number="160801">
  <Name="Shaun">
    <Age="18">
      <Program="Communication">
        <ID Number="160802">
          <Name="Linh">
            <Age="20">
              <Program="Accounting">
                ..... </University>
```

Structured Data

ID	Name	Age	Program
160801	Shaun	18	Communication
160802	Linh	20	Accounting
160803	Ahmed	19	Psychology



Gold Price Charts & Historical Data - GoldPrice.org



Market research report

2.1.1. Các loại dữ liệu kinh doanh

- Các loại dữ liệu kinh doanh:

• **Có cấu trúc (Structured Data):**

- Được tổ chức dưới dạng bảng với các hàng và cột như cơ sở dữ liệu, hệ thống ERP, CRM.
- VD: Giao dịch bán hàng, danh sách khách hàng, lịch sử mua sắm, ...

• **Phi cấu trúc (Unstructured Data):**

- Không theo một cấu trúc cụ thể, thường phức tạp hơn để phân tích
- VD: email, báo cáo, đánh giá từ mạng xã hội,

• **Bán cấu trúc (Semi-Structured Data):**

- Có một phần cấu trúc, nhưng không theo một mô hình rõ ràng
- VD: các file XML, JSON, log



2.1.1. Các loại dữ liệu kinh doanh

- **Các loại dữ liệu kinh doanh:**

- ***Dữ liệu thời gian thực (Real-Time Data):***

- Được thu thập và cập nhật liên tục trong thời gian thực.
- Các hệ thống theo dõi thời gian thực giúp doanh nghiệp đưa ra quyết định kịp thời dựa trên dữ liệu mới nhất
- VD: dữ liệu từ cảm biến IoT, thông tin giao dịch trực tuyến.

- ***Dữ liệu từ bên ngoài (External Data):***

- Được thu thập từ bên ngoài doanh nghiệp,
- VD: dữ liệu thị trường, dữ liệu về giá của đối thủ cạnh tranh, hoặc dữ liệu kinh tế vĩ mô.



2.1.2. Các loại kiểu dữ liệu

- Các loại kiểu dữ liệu:

- Dữ liệu số (numeric)
 - Liên tục (Continuous) và Rời rạc (Discrete)
 - Interval-scaled và Ratio-scaled
- Dữ liệu phân loại (category)
 - Nominal (categorical)
 - Binary
 - Ordinal



2.1.2. Các loại kiểu dữ liệu

- **Nominal:** danh mục, trạng thái hoặc “names of things”
 - **VD:** Màu tóc = {màu nâu vàng, đen, vàng, nâu, xám, đỏ, trắng}
 - Tình trạng hôn nhân, nghề nghiệp, số ID, zip code
- **Binary**
 - Thuộc tính nominal chỉ có 2 trạng thái (0 và 1)
 - Nhị phân đối xứng (Symmetric binary): cả hai đều quan trọng như nhau. **VD:** giới tính
 - Nhị phân bất đối xứng (Asymmetric binary): không quan trọng như nhau. **VD:** kết quả xét nghiệm y tế (dương tính, âm tính)

Quy ước (Convention): gán 1 cho kết quả quan trọng hơn. **VD:** dương tính với HIV

2.1.2. Các loại kiểu dữ liệu

- Ordinal

- Các giá trị có thứ tự có ý nghĩa (xếp hạng) nhưng độ lớn giữa các giá trị liên tiếp không được biết.
- **VD:** Kích thước = {nhỏ, trung bình, lớn}, Điểm = {A, B, C, D, E, F}, cấp bậc, quân hàm.



2.1.2. Các loại kiểu dữ liệu

- **Numeric:** định lượng, có thể đo được, giá trị nguyên hoặc thực. 2 loại:
 - Interval-scaled (*Thuộc tính tỷ lệ khoảng thời gian*)
 - Loại dữ liệu được đo theo thang đo, khoảng cách giữa hai điểm được chuẩn hóa và bằng nhau. Không có điểm 0 thực sự
 - Dữ liệu không thể nhân hoặc chia, nhưng có thể trừ hoặc cộng
 - VD: Độ C, Độ F, ngày trong tháng
 - Ratio-scaled (*Thuộc tính tỷ lệ*)
 - Có điểm 0 thực sự
 - Có thể nói một dữ liệu là bội (hoặc tỷ lệ) với một dữ liệu khác
 - VD: number_of_words, số lượng tiền tệ, độ dài, số năm kinh nghiệm

2.1.2. Các loại kiểu dữ liệu

- Thuộc tính rời rạc (Discrete Attribute)

- Chỉ có một tập giá trị hữu hạn hoặc vô hạn đếm được
- VD: zip code, nghề nghiệp, tập hợp các từ trong bộ sưu tập tài liệu
- Được biểu diễn dưới dạng số nguyên, số thực
- Thuộc tính binary là trường hợp đặc biệt của thuộc tính rời rạc

- Thuộc tính liên tục (Continuous Attribute)

- Giá trị thuộc tính: số thực
- VD: nhiệt độ, chiều cao hoặc cân nặng
- Trên thực tế, các giá trị thực chỉ có thể được đo lường và biểu diễn bằng số lượng chữ số hữu hạn
- Thường được biểu diễn dưới dạng các biến dấu phẩy động



2.1. Dữ liệu kinh doanh

	A	B	C	D	E	F	G	H	I	J
1	Purchase Orders									
2										
3	Supplier	Order No	Item No.	Item Description	Item Cost	Quantity	Cost per order	A/P Terms (Months)	Order Date	Arrival Date
4	Spacetime Technologies	A0111	6489	O-Ring	\$ 3.00	900	\$ 2,700.00	25	10/10/11	10/18/11
5	Steelpin Inc.	A0115	5319	Shielded Cable/ft.	\$ 1.10	17,500	\$ 19,250.00	30	08/20/11	08/31/11
6	Steelpin Inc.	A0123	4312	Bolt-nut package	\$ 3.75	4,250	\$ 15,937.50	30	08/25/11	09/01/11
7	Steelpin Inc.	A0204	5319	Shielded Cable/ft.	\$ 1.10	16,500	\$ 18,150.00	30	09/15/11	10/05/11
8	Steelpin Inc.	A0205	5677	Side Panel	\$195.00	120	\$ 23,400.00	30	11/02/11	11/13/11
9	Steelpin Inc.	A0207	4312	Bolt-nut package	\$ 3.75	4,200	\$ 15,750.00	30	09/01/11	09/10/11
10	Alum Sheeting	A0223	4224	Bolt-nut package	\$ 3.95	4,500	\$ 17,775.00	30	10/15/11	10/20/11
11	Alum Sheeting	A0433	5417	Control Panel	\$255.00	500	\$ 127,500.00	30	10/20/11	10/27/11
12	Alum Sheeting	A0443	1243	Airframe fasteners	\$ 4.25	10,000	\$ 42,500.00	30	08/08/11	08/14/11
13	Alum Sheeting	A0446	5417	Control Panel	\$255.00	406	\$ 103,530.00	30	09/01/11	09/10/11
14	Spacetime Technologies	A0533	9752	Gasket	\$ 4.05	1,500	\$ 6,075.00	25	09/20/11	09/25/11
15	Spacetime Technologies	A0555	6489	O-Ring	\$ 3.00	1,100	\$ 3,300.00	25	10/05/11	10/10/11

Nominal

Nominal

Nominal

Nominal

Ratio

Ratio

Ratio

Ratio


Interval

Interval

2.2. Các kỹ thuật tiền xử lý dữ liệu

- Tiền xử lý dữ liệu: quá trình xử lý dữ liệu thô ban đầu để trở thành dữ liệu sạch, phù hợp cho các bước phân tích tiếp theo.
- Lựa chọn kỹ thuật tiền xử lý dữ liệu dựa trên mục tiêu của nghiên cứu.

Steps for data preprocessing



Tiền xử lý dữ liệu – Cần lưu ý

Completeness (Đầy đủ)

Từng mẫu thu thập nên đầy đủ thông tin các trường thuộc tính cần thiết

Homogeneity (Đồng nhất)

Thu thập dữ liệu từ nhiều nguồn

Rating “1,2,3” & “A,B,C”
Age = “23” & Birthday = “01/01/2023”

Integrity (Trung thực)

Nguồn thu thập chính thống, đảm bảo mẫu thu được chứa giá trị chính xác trên thực tế.

Structures (Cấu trúc)

C	D	E	F	G
Population	Under15	Over60	Fertil	LifeExpi
13724	40.24	5.68	3.64	54
14075	46.73	3.95	5.77	55
23852	40.72	4.54	4.35	64
90796	22.87	9.32	1.79	75
29955	28.84	9.17	2.44	75
247	37.37	6.02	3.46	72
28541	28.9	6.38	2.38	68
3395	22.05	18.59	2.07	77

	X ₁	X ₂	X ₃	X ₄	X ₅
	sepal length	sepal width	petal length	petal width	class
x ₁	5.9	3.0	4.2	1.5	Iris-versicolor
x ₂	6.9	3.1	4.9	1.5	Iris-versicolor
x ₃	6.6	2.9	4.6	1.3	Iris-versicolor
x ₄	4.6	3.2	1.4	0.2	Iris-setosa
x ₅	6.0	2.2	4.0	1.0	Iris-versicolor
x ₆	4.7	3.2	1.3	0.2	Iris-setosa
x ₇	6.5	3.0	5.8	2.2	Iris-virginica
x ₈	5.8	2.7	5.1	1.9	Iris-virginica
⋮	⋮	⋮	⋮	⋮	⋮
x ₁₄₉	7.7	3.8	6.7	2.2	Iris-virginica
x ₁₅₀	5.1	3.4	1.5	0.2	Iris-setosa


2.2. Các kỹ thuật tiền xử lý dữ liệu

- **Làm sạch dữ liệu (Data cleaning)**

- Điền vào các giá trị còn thiếu
- Khử dữ liệu nhiễu
- Xác định hoặc loại bỏ các giá trị ngoại lệ, sai lệch
- Giải quyết các dữ liệu không nhất quán, mâu thuẫn

- **Tích hợp dữ liệu (Data integration):**

- Tổng hợp, tích hợp dữ liệu từ nhiều CSDL, khối dữ liệu hoặc tập tin




2.2. Các kỹ thuật tiền xử lý dữ liệu

- **Rút gọn dữ liệu (Data reduction)**
 - Giảm chiều dữ liệu (Dimensionality reduction)
 - Giảm số lượng (Numerosity reduction)
 - Nén dữ liệu (Data compression)
- **Biến đổi và rời rạc hóa dữ liệu (Data transformation, data discretization):**
 - Chuẩn hóa dữ liệu (Normalization)
 - Hệ thống khái niệm phân cấp (Concept hierarchy generation)




Thời gian dành cho phân tích dữ liệu ra sao?



- Thu thập dữ liệu: 19%
- Xử lý và làm sạch dữ liệu: 60%
- Tạo tập dữ liệu huấn luyện: 3%
- Khai thác dữ liệu: 9%
- Cải thiện thuật toán: 4%
- Khác: 5%

Data science report, CrowdFlower, 2016



3

Một số phương pháp phân tích cơ bản

Một số phương pháp phân tích dữ liệu cơ bản



1. Cluster Analysis
2. Cohort Analysis
3. Regression Analysis
4. Neural Network
5. Factor Analysis
6. Data Mining
7. Text Analysis
8. Time Series Analysis
9. Decision Trees
10. Conjoint Analysis

Một số phương pháp phân tích dữ liệu cơ bản

- Phân tích cụm (Cluster Analysis)

- Phân dữ liệu thành các nhóm tương đồng giúp khám phá được các cấu trúc ẩn bên trong của dữ liệu.
- Trong PTDLKD, phân khúc thị trường thông qua việc nhóm các khách hàng theo vị trí địa lí, hành vi mua sắm,
- VD: Chia khách hàng thành các nhóm dựa trên hành vi mua sắm của họ để tối ưu hóa chiến lược marketing dành riêng cho từng nhóm khách hàng



Một số phương pháp phân tích dữ liệu cơ bản

- Phân tích nhóm đối tượng (Cohort Analysis)

- Phân tích các nhóm khách hàng (cohort) theo một đặc điểm chung, có hành vi tương đồng trong một khoảng thời gian quá khứ, đưa ra dự đoán các hành vi trong tương lai.
- VD: Phân tích hành vi khách hàng theo từng nhóm được tạo ra từ thời gian bắt đầu sử dụng sản phẩm (nhóm đăng ký vào tháng 1, 2,...). Mỗi nhóm sẽ được phân tích để xác định sự thay đổi hành vi theo thời gian, tỷ lệ giữ chân người dùng (retention rate) theo tháng cho các nhóm người dùng đăng ký vào tháng khác nhau.
- Mỗi cohort có thể có các xu hướng khác nhau, giúp đưa ra quyết định chiến lược cho từng cohort.



Một số phương pháp phân tích dữ liệu cơ bản

- Phân tích hồi quy (Regression Analysis)

- Mô hình hoá, xác định mối quan hệ giữa một biến phụ thuộc và một hoặc nhiều biến độc lập.
- Hiểu và dự đoán cách mà các biến ảnh hưởng lẫn nhau. Khám phá các xu hướng và dự báo kết quả tương lai dựa trên dữ liệu lịch sử.
- VD: Dự đoán doanh thu của công ty dựa trên chi tiêu quảng cáo, số lượng sản phẩm bán ra, và các yếu tố khác.
- Tính hệ số hồi quy (coefficients) cho mỗi biến độc lập, cho thấy mức độ ảnh hưởng của các yếu tố này đối với biến phụ thuộc. Nếu hệ số hồi quy là dương, biến độc lập tăng lên sẽ dẫn đến biến phụ thuộc tăng.



Một số phương pháp phân tích dữ liệu cơ bản

- Mạng nơ-ron nhân tạo (Neural Networks)

- Mô phỏng cách bộ não con người hoạt động, có khả năng tự học và thích nghi với dữ liệu và các mô hình phức tạp để giải quyết các vấn đề, thực hiện các nhiệm vụ như phân lớp, hồi quy, nhận dạng, ...
- VD:
 - Dự đoán hành vi khách hàng dựa trên lịch sử giao dịch (khách hàng có thể rời bỏ hay không)
 - Dự đoán doanh số dựa trên tập dữ liệu lịch sử
 - Phân tích được quan điểm khách hàng từ mạng xã hội nhằm tối ưu được chiến lược tiếp thị và kinh doanh.



Một số phương pháp phân tích dữ liệu cơ bản

- Phân tích nhân tố (Factor Analysis)

- Xác định các biến tiềm ẩn hoặc các thành phần có ảnh hưởng đến các biến tương quan. Kỹ thuật giảm chiều dữ liệu bằng cách tóm gọn các biến tương quan thành một biến tiềm ẩn.
- VD:
 - Xác định biến tiềm ẩn (sự hài lòng của khách hàng) từ nhiều câu hỏi trong khảo sát
 - Xác định các yếu tố then chốt ảnh hưởng đến quyết định mua xe ô tô (thiết kế, giá trị và hiệu năng)
- Các yếu tố rút ra giúp giảm số lượng biến, có thể tập trung cải thiện các yếu tố quan trọng này nhằm thu hút khách hàng.

Một số phương pháp phân tích dữ liệu cơ bản

- Khai thác dữ liệu (Data Mining)

- Khám phá các mẫu hoặc kiến thức ẩn, các mối quan hệ, xu hướng trong các tập dữ liệu.
- Phân tích và tìm ra được các quy tắc hoặc luật kết hợp
- VD: Phát hiện các mẫu hành vi hoặc quy luật mua sắm của khách hàng từ các giao dịch trong quá khứ.
- Các quy luật có thể được sử dụng để tạo ra các chiến lược bán hàng, sắp xếp hàng hóa, khuyến nghị



Một số phương pháp phân tích dữ liệu cơ bản


- Phân tích văn bản (Text Analysis)

- Xử lý và phân tích dữ liệu văn bản để rút ra thông tin có giá trị.
- Hiểu được ý kiến và hành vi của khách hàng thông qua các đánh giá sản phẩm
- VD:
 - Phân tích phản hồi khách hàng từ các đánh giá trên mạng để hiểu cảm xúc của họ (positive, negative, neutral).
 - Phân tích các đánh giá về sản phẩm mới, phân loại chúng thành các nhóm như thiết kế, hiệu suất và chất lượng, cho thấy khách hàng khen ngợi thiết kế nhưng lo ngại về mức tiêu thụ nhiên liệu, từ đó điều chỉnh chiến dịch tiếp thị sản phẩm.

Một số phương pháp phân tích dữ liệu cơ bản

- Phân tích chuỗi thời gian (Time-series Analysis)

- Khám phá các xu hướng, mùa vụ, chu kỳ, và yếu tố ngẫu nhiên, từ đó dự đoán tương lai và hiểu rõ hơn về các biến động theo thời gian.
- Xác định nguyên nhân gây ra biến động và xây dựng mô hình dự đoán, phát hiện điểm bất thường và đánh giá tác động của các sự kiện trong quá khứ.
- VD:
 - Dự báo doanh thu hàng tháng, theo mùa trong năm tiếp theo dựa trên dữ liệu lịch sử.
 - Xác định được xu hướng tăng doanh số vào dịp lễ và sự ưa chuộng màu sắc của khách hàng, giúp quyết định chính sách nhập hàng, khuyến mãi dịp lễ hội.



Một số phương pháp phân tích dữ liệu cơ bản

- Cây quyết định (Decision Trees)

- Phân loại hoặc dự đoán kết quả dựa trên các điều kiện, phản ánh các quyết định và kết quả dưới dạng cấu trúc cây.
- Được ứng dụng trong phân lớp, hồi quy và dự đoán, đưa ra các quyết định chiến lược và đánh giá rủi ro.
- VD:
 - Dự đoán khả năng khách hàng sẽ mua sản phẩm dựa trên các đặc điểm như tuổi, thu nhập, hoặc lịch sử mua sắm.
 - Dự đoán khả năng cho khách hàng vay dựa trên lịch sử tín dụng và thu nhập, đưa ra các quyết định chính xác hơn và giảm thiểu rủi ro.

Một số phương pháp phân tích dữ liệu cơ bản

- Phân tích thuộc tính (Conjoint Analysis)

- Kỹ thuật thống kê dùng trong nghiên cứu thị trường để hiểu sở thích và ưu tiên của người tiêu dùng đối với các sản phẩm hoặc dịch vụ.
- Xác định mức độ quan trọng của từng thuộc tính sản phẩm trong quyết định mua hàng. Mục tiêu là tìm ra sự kết hợp tối ưu của các thuộc tính để đáp ứng nhu cầu của khách hàng.
- VD:
 - Xác định mức độ quan trọng của các yếu tố như giá cả, chất lượng, và cấu hình khi khách hàng lựa chọn sản phẩm. Công ty sử dụng thông tin khách hàng để cao cấu hình để điều chỉnh cấu hình sản phẩm và định giá nhằm tối đa hóa doanh số.

4

Đo lường dữ liệu

1. Tổng thể và mẫu
2. Đo lường dữ liệu
3. Đo lường vị trí trung tâm
4. Đo lường sự biến thiên của dữ liệu
5. Đo lường hình dáng phân tán của dữ liệu

4.1. Tổng thể và mẫu

- Tổng thể (Population)

- Tập hợp tất cả các đối tượng hoặc giá trị muốn nghiên cứu hoặc phân tích.
- Có thể là rất lớn. Việc thu thập dữ liệu có thể tốn kém và mất nhiều thời gian, đôi khi là không khả thi.
- VD:
 - Population là tất cả sinh viên của một trường đại học để phân tích tình trạng học tập.
 - Population là khảo sát tất cả các khách hàng của cửa hàng bán lẻ khi phân tích hành vi mua hàng của khách hàng.



4.1. Tổng thể và mẫu

- Mẫu (Samples)

- Một tập con của population, được chọn để đại diện cho population trong nghiên cứu.
- Thông qua mẫu, có thể ước lượng các đặc điểm của population mà không cần phải thu thập dữ liệu từ toàn bộ population.
- Giúp tiết kiệm thời gian và chi phí khi nghiên cứu.
- VD:
 - Samples là chọn ngẫu nhiên 500 sinh viên đến từ mỗi khoa của một trường đại học để phân tích tình trạng học tập.
 - Samples là khảo sát ngẫu nhiên 100 khách hàng của cửa hàng bán lẻ khi phân tích hành vi mua hàng của khách hàng.

4.2. Đo lường dữ liệu

- Quan trọng trong việc hiểu và giải thích tập dữ liệu.
- Dữ liệu có thể được đo bằng nhiều thống kê mô tả nhằm đánh giá và phân tích ý nghĩa của các giá trị,
 - Số lượng (Count)
 - Giá trị nhỏ nhất (Min)
 - Giá trị lớn nhất (Max)
 - Trung bình (Mean)
 - Trung vị (Median)
 - Mốt (Mode)
 - Tứ phân vị (Quantile)
 - Khoảng biến thiên (Range)
 - Phương sai (Variance)
 - Độ lệch chuẩn (Standard Deviation)
 - Hệ số biến thiên (Coefficient of Variation)
 - Độ lệch (Skewness)
 - Độ nhọn (Kurtosis).

4.3. Đo lường vị trí trung tâm

- Bước khởi đầu quan trọng trong PTDL nhằm phản ánh khu vực tập trung chủ yếu của các quan sát.
- Các vị trí trung tâm:
 - Trung bình (mean)
 - Trung vị (median)
 - Mốt (mode)
 - Các phân vị (quantiles)
- Trung bình phổ biến, nhưng không phải phù hợp với mọi loại dữ liệu.
- Trung vị, mode và các phân vị thường được ưu tiên sử dụng khi dữ liệu có các giá trị ngoại lệ hoặc phân bố không đối xứng.
- Việc lựa chọn thước đo vị trí trung tâm phù hợp phụ thuộc vào đặc điểm của tập dữ liệu và mục tiêu phân tích.



4.3.1. Trung bình (Mean)

- Là giá trị trung bình của tập dữ liệu.
- Bị ảnh hưởng bởi giá trị quan sát được.
- Thường được sử dụng cho dữ liệu intervals và ratios
- Trung bình mẫu:

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n} \quad (1)$$

- $\bar{x}$: trung bình mẫu
- n : số lượng giá trị trong mẫu
- x_i : các giá trị trong mẫu

4.3.1. Trung bình (Mean)

- Trung bình tổng thể:

$$\mu = \frac{\sum_{i=1}^N x_i}{N} \quad (2)$$

- μ : trung bình tổng thể
- N : số lượng giá trị trong tổng thể
- x_i : các giá trị trong tổng thể



4.3.2. Mode

- Là giá trị xuất hiện nhiều nhất trong tập dữ liệu.
- Phản ánh tần suất xuất hiện của các giá trị
- Không bị ảnh hưởng bởi các giá trị outlier hay các giá trị ở hai đầu của phân phối (các giá trị lớn nhất và nhỏ nhất).
- Nếu trong mẫu không có giá trị nào lặp lại thì không có mode.
- Thường được sử dụng cho dữ liệu category (nominal)



4.3.3. Trung vị (Median)

- Trung vị (median hoặc 50th percentile) là một thước đo xu hướng trung tâm, đại diện cho giá trị phân chia một tập dữ liệu đã được sắp xếp thành hai phần bằng nhau về số lượng quan sát.
 - Số phần tử lẻ: trung vị là giá trị chính giữa.
 - Số phần tử chẵn: trung vị là trung bình của hai giá trị ở giữa.

$$Q_{50} = \frac{x\left(\left\lceil \frac{n}{2} \right\rceil\right) + x\left(\left\lfloor \frac{n}{2} + 1 \right\rfloor\right)}{2} \quad (3)$$

$[i]$: số tự nhiên nhỏ nhất, lớn hơn hoặc bằng i
 $\lfloor i \rfloor$: số tự nhiên lớn nhất, nhỏ hơn hoặc bằng i
 $x_{(i)}$: giá trị tại vị trí i trong mẫu x (x sắp xếp tăng dần)
 n : số lượng giá trị trong mẫu x

- Ít bị ảnh hưởng bởi các giá trị outlier, thường được sử dụng để mô tả dữ liệu có phân bố không đối xứng.



4.3.4. Tứ phân vị (Quantiles)

- Mô tả cách dữ liệu phân bố và mức độ phân tán của tập dữ liệu.
- Tập dữ liệu được sắp xếp tăng dần và chia thành 4 phần có số lượng phần tử bằng nhau. 3 giá trị nằm ở vị trí chia cắt 4 phần là tứ phân vị.

$\frac{i(n+1)}{4}$: là số nguyên

$$Q_i = x\left(\frac{i(n+1)}{4}\right) \quad (4)$$

$\frac{i(n+1)}{4}$: không là số nguyên

$$Q_i = \frac{x\left(\left\lfloor \frac{i(n+1)}{4} \right\rfloor\right) + x\left(\left\lceil \frac{i(n+1)}{4} \right\rceil\right)}{2} \quad (5)$$



4.4. Đo lường sự biến thiên của dữ liệu

- Để đánh giá tính đại diện và độ tin cậy của một mẫu.
- Được sử dụng để mô tả mức độ phân tán của dữ liệu xung quanh giá trị trung bình.
- Các tham số:
 - Khoảng biến thiên (Range)
 - Khoảng tứ phân vị (Interquartile Range - IQR)
 - Phương sai (Variance)
 - Độ lệch chuẩn (Standard deviation)
 - Sai số chuẩn (Standard error)



4.4.1. Khoảng biến thiên (Range)

- Là sự chênh lệch giữa giá trị lớn nhất và giá trị nhỏ nhất.

$$Range(x) = \text{Max}(x) - \text{Min}(x) \quad (6)$$



4.4.2. Khoảng tứ phân vị (IQR)

- Đánh giá mức độ phân tán của các giá trị trong dữ liệu
- Giúp hiểu được khoảng cách giữa các tứ phân vị và xác định được phạm vi của 50% giữa các giá trị trong một tập dữ liệu

$$IQR = Q_3 - Q_1 \quad (7)$$

- Dữ liệu có IQR lớn sẽ có độ phân tán rộng, dữ liệu có IQR nhỏ có thể có sự phân bố tập trung hơn
- Có thể được sử dụng để phát hiện các giá trị outlier trong dữ liệu. Outlier nếu nó nhỏ hơn $Q_1 - 1.5 * IQR$ hoặc lớn hơn $Q_3 + 1.5 * IQR$
- Không thể hiện được toàn bộ đặc điểm dữ liệu, chỉ tập trung vào phạm vi giữa Q_1 và Q_3 , do đó có thể bỏ qua các đặc điểm khác của dữ liệu (như các giá trị cực trị hoặc phân phối không đều)



4.4.3. Phương sai (Variance) và Độ lệch chuẩn (Standard deviation)

- Là thước đo mức độ khác nhau của các điểm dữ liệu so với giá trị trung bình.
- Đo lường khoảng cách giữa một tập hợp dữ liệu (số) với giá trị trung bình (trung bình) của chúng.
- Phương sai:

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1} \quad (8)$$

- Độ lệch chuẩn:

$$s = \sqrt{s^2} = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}} \quad (9)$$

4.4.4. Sai số chuẩn (Standard error)

- Được sử dụng để đánh giá độ lệch chuẩn của phân phối mẫu.
- Cho biết mức độ biến động của các ước lượng mẫu, tức là nếu lấy nhiều mẫu khác nhau từ cùng một population, SE cho biết sự phân tán của các giá trị trung bình mẫu xung quanh giá trị trung bình population.
- SE càng nhỏ, thì trung bình mẫu ước tính càng gần với trung bình population thực tế, cho thấy rằng mẫu được chọn có độ chính xác cao trong việc ước tính các tham số của population.

$$SE = \frac{s}{\sqrt{n}} \quad (10)$$



4.5. Đo lường về hình dáng của phân phối

- Từ hình dáng phân bố có thể hiểu được các đặc trưng của tập dữ liệu và đánh giá lại độ chính xác.
- Histogram - công cụ trực quan để minh họa các đặc trưng này.
- Các hình dáng phân bố:
 - Độ lệch (Skewness)
 - Độ nhọn (Kurtosis)



4.5.1. Độ lệch (Skewness)


- Là thước đo tính chất đối xứng của phân phối xác suất.
- Phân bố đối xứng này có hàm mật độ đối xứng qua đường thẳng và đi qua giá trị trung bình.

$$SK = \frac{n}{(n-1)(n-2)} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^3 \quad (11)$$



4.5.1. Độ lệch (Skewness)

- $SK = 0$: Phân phối là đối xứng, phân phối chuẩn
- $SK > 0$: Phân phối có độ lệch phải (positive skew), phần đuôi của phân phối kéo dài ra phía bên phải (phân phối lệch phải).
- $SK < 0$: Phân phối có độ lệch trái (negative skew), phần đuôi của phân phối kéo dài ra phía bên trái (phân phối lệch trái).




4.5.2. Độ nhọn (Kurtosis)

- Dùng để đo lường đặc tính độ nhọn hoặc độ phẳng của phân phối dữ liệu, đặc biệt là so với phân phối chuẩn.
- Đánh giá sự tập trung của dữ liệu xung quanh trung bình, cũng như độ dài của các đuôi phân phối, từ đó đưa ra những nhận định về rủi ro hay sự biến động của dữ liệu.

$$Kurtosis = \frac{n(n+1)}{(n-1)(n-2)(n-3)} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^4 - \frac{3(n-1)^2}{(n-2)(n-3)} \quad (12)$$

4.5.2. Độ nhọn (Kurtosis)


- Kurtosis = 3: phân phối được gọi là **mesokurtic**, tức là có hình dạng và đặc tính độ nhọn tương tự phân phối chuẩn.
- Kurtosis > 3, phân phối có độ nhọn lớn, gọi là **leptokurtic**, có đuôi dài và đỉnh nhọn, có nhiều giá trị outliers.
- Nếu kurtosis < 3, phân phối có độ nhọn nhỏ, gọi là **platykurtic**, có đuôi ngắn và đỉnh phẳng, ít giá trị outlier hơn và dữ liệu phân bố đồng đều hơn



	Mesokurtic	Platykurtic	Leptokurtic
Tailedness	Medium-tailed	Thin-tailed	Fat-tailed
Outlier frequency	Medium	Low	High
Kurtosis	Moderate (3)	Low (< 3)	High (> 3)
Excess kurtosis	0	Negative	Positive
Example distribution	Normal	Uniform	Laplace


$$\text{Excess Kurtosis} = \text{Kurtosis} - 3$$

4.5.2. Độ nhọn (Kurtosis)




Platykurtic

Phân phối (các thanh màu xám) không theo phân phối chuẩn (đường cong màu xanh lá)
Phân phối có độ nhọn thấp, đuôi ngắn.



Mesokurtic

Phân phối (các thanh màu xám) tương ứng với phân phối chuẩn (đường cong màu xanh lá)
Phân phối có độ nhọn trung bình, đuôi trung bình



Leptokurtic

Phân phối (các thanh màu xám) không tuân theo phân phối chuẩn (đường cong màu xanh lá), nhưng tương ứng với phân phối Laplace (đường cong màu xanh dương)
Phân phối có độ nhọn cao, đuôi dài

Đo lường dữ liệu: Bài tập

BTLT1


Cho một nhóm 10 học sinh trong lớp và điểm số của họ như sau:

{45, 52, 47, 50, 63, 58, 52, 51, 56, 60}

Hãy tính các thông số thống kê sau:

1. Trung bình (Mean)
2. Trung vị (Median)
3. Mốt (Mode)
4. Tứ phân vị (Quantiles)
5. Phương sai (Variance)
6. Độ lệch chuẩn (Standard Deviation)
7. Khoảng tứ phân vị (IQR)
8. Độ lệch (Skewness)
9. Độ nhọn (Kurtosis)






5 Trực quan hóa dữ liệu


1. Trực quan hóa dữ liệu
2. Một số dạng biểu đồ thông dụng
3. Các bước trực quan hóa dữ liệu

5.1. Trực quan hóa dữ liệu


- Sử dụng đồ họa để biểu diễn dữ liệu nhằm giúp người dùng dễ dàng hiểu và phân tích các mẫu, xu hướng và thông tin từ dữ liệu.
- Giúp giảm sự phức tạp và làm cho dữ liệu trở nên dễ tiếp cận và dễ hiểu hơn.




Biểu đồ thanh
(Bar chart)



Biểu đồ đường
(Line chart)




Biểu đồ tròn
(Pie chart)



Biểu đồ bong bóng
(Bubble chart)



Biểu đồ đám mây
(Wordcloud)




Biểu đồ nhiệt
(Heat map)

5.2. Một số dạng biểu đồ thông dụng

- Biểu đồ cột (Bar Chart)


- Mục đích: So sánh giá trị giữa các nhóm hoặc thể hiện tần suất xuất hiện của một mục trong một tập dữ liệu.
- Ứng dụng: Dùng để so sánh các giá trị của từng danh mục, ví dụ như số lượng bán hàng theo từng năm, theo từng khu vực.
- VD: So sánh doanh thu theo từng quý trong một năm.



5.2. Một số dạng biểu đồ thông dụng

- Biểu đồ đường (Line Chart):


- Mục đích: Thể hiện sự thay đổi của một giá trị qua thời gian.
- Ứng dụng: Dùng để hiển thị các dữ liệu chuỗi thời gian (time series), ví dụ như sự thay đổi của giá cổ phiếu, nhiệt độ theo từng ngày, doanh thu theo từng tháng.
- VD : Dự báo doanh thu trong tương lai dựa trên xu hướng hiện tại.



5.2. Một số dạng biểu đồ thông dụng

- Biểu đồ tròn (Pie Chart):

- Mục đích: Hiển thị tỷ lệ phần trăm của các phần trong tổng thể.
- Ứng dụng: Dùng để thể hiện tỷ lệ phân chia các thành phần của một tổng thể. Tuy nhiên, biểu đồ tròn không thích hợp khi có quá nhiều phần tử hoặc các phần tương đối gần nhau.
- VD: Thể hiện tỷ lệ phân chia thị phần của các công ty trong một ngành.




5.2. Một số dạng biểu đồ thông dụng

- Biểu đồ tán xạ (Scatter Plot):

- Mục đích: Thể hiện mối quan hệ giữa hai biến số.
- Ứng dụng: Dùng để phân tích sự liên kết giữa hai yếu tố.
- VD: Kiểm tra mối quan hệ giữa lượng mưa và sản lượng lúa; giữa chi tiêu quảng cáo và doanh thu; hoặc chiều cao và cân nặng


Scatter Plot Correlation Examples



5.2. Một số dạng biểu đồ thông dụng

- Biểu đồ hộp (Box Plot):


- Mục đích: Tóm tắt phân phối của một tập dữ liệu thông qua các phần tử như giá trị tối thiểu, tứ phân vị (Q_1 , Q_3), trung vị và giá trị tối đa.
- Ứng dụng: Dùng để phát hiện các outliers (giá trị bất thường) và đánh giá phạm vi và phân phối của dữ liệu.
- VD: Đo lường phân phối điểm thi của học sinh trong một lớp học.



5.2. Một số dạng biểu đồ thông dụng

- Biểu đồ nhiệt (Heatmap):



- Mục đích: Hiển thị dữ liệu qua các ô màu sắc, giúp nhận diện các mẫu và mối quan hệ trong dữ liệu.
- Ứng dụng: Dùng để phân tích ma trận hoặc các dữ liệu dạng bảng, đặc biệt là trong các tình huống mà bạn muốn so sánh mức độ hoặc tần suất giữa các nhóm.
- VD: Phân tích các mối quan hệ giữa các biến số trong một bảng dữ liệu.



5.2. Một số dạng biểu đồ thông dụng

- Biểu đồ phân phối (Histogram):


- Mục đích: Thể hiện phân phối tần suất của một tập dữ liệu theo các khoảng giá trị.
- Ứng dụng: Dùng để phân tích độ phân bố của dữ liệu, ví dụ như phân phối độ tuổi trong một nhóm người.
- VD: Đo lường phân phối độ tuổi trong một cuộc khảo sát.



5.2. Một số dạng biểu đồ thông dụng

- Biểu đồ tán xạ 3D (3D Scatter Plot):

- Mục đích: Dùng để trực quan hóa mối quan hệ giữa ba biến số.
- Ứng dụng: Khi cần so sánh giữa 3 biến số
- VD: Phân tích mối quan hệ, thể hiện sự thay đổi giữa giá trị sản phẩm, thời gian giao hàng và chi phí vận chuyển.



5.3. Các bước trực quan hóa dữ liệu

- **Thu thập và làm sạch dữ liệu** (loại bỏ các giá trị thiếu, kiểm tra và xử lý các giá trị bất thường, chuẩn hóa dữ liệu nếu cần)
- **Chọn loại biểu đồ phù hợp**
- **Thực hiện trực quan hóa** bằng cách sử dụng các công cụ trực quan hóa phổ biến như Excel, Tableau, Power BI, Matplotlib (Python), hoặc ggplot2 (R).
- **Thiết kế biểu đồ** sao cho rõ ràng và dễ hiểu. Đảm bảo rằng các trục và chú thích được mô tả đầy đủ.
- **Phân tích kết quả** để rút ra các kết luận: nhận diện các mẫu, xu hướng, hoặc phát hiện các vấn đề (như các giá trị bất thường).

Tổng kết chương



Tổng quan về Phân tích dữ liệu

1. Phân tích dữ liệu
2. Phân tích dữ liệu kinh doanh



Dữ liệu trong PTKD

1. Dữ liệu kinh doanh
2. Các kỹ thuật tiền xử lý dữ liệu



Một số phương pháp phân tích cơ bản

1. Giới thiệu
2. Xây dựng luật phân lớp
3. Xác định lớp cho các mẫu



Tổng kết chương



Đo lường dữ liệu

1. Tổng thể và mẫu
2. Đo lường dữ liệu
3. Đo lường vị trí trung tâm
4. Đo lường sự biến thiên của dữ liệu
5. Đo lường hình dáng phân tán của dữ liệu



Trực quan hóa dữ liệu

1. Trực quan hóa dữ liệu
2. Một số loại biểu đồ phổ biến
3. Các bước trực quan hóa dữ liệu



Tài liệu tham khảo

- Tài liệu, sách:

- (1). Nguyễn Đình Thuần, Giáo trình Phân tích dữ liệu kinh doanh, NXB. ĐHQG-HCM, 2024
- (2). James R. Evans, "Business Analytics, Methods, Models, and Decisions", 3rd Edition, Prentice Hall, 2019.
- (3). Aileen Nielsen, "Practical Time Series Analysis: Prediction with Statistics and Machine Learning", O'Reilly Media, 2020
- (4). Peter Bruce, Andrew Bruce, and Peter Gedeck, "Practical Statistics for Data Scientists: 50+ Essential Concepts Using R and Python", O'Reilly Media, 2020

- Data for experiments:

- Kaggle: <https://www.kaggle.com/>
- UCI repository: <http://archive.ics.uci.edu/>



THANKS!

Any questions?

